

一种面向众包回归问题的在线聚合方法

渐令¹, 陈兴科², 周鹏¹

(1. 中国石油大学(华东) 经济管理学院, 青岛 266580; 2. 中国石油大学(华东) 理学院, 青岛 266580)

摘 要 众包作为互联网时代一种开放式知识生产模式, 具有自愿、协同等特征, 已成为低成本获取群体智力资源的重要途径, 是解决诸多复杂问题的有效手段。众包服务高效地从非专业人群中收集大量样本标签, 然而这些标签数据富含噪音, 标签质量控制问题已成为制约后续数据挖掘效果提升的瓶颈。为有效改善众包数据的标签质量, 本文在半监督众包回归框架下基于标准指数梯度算法提出了一种新的众包回归在线聚合方法, 该方法依据工作人员的动态表现, 实时调整对其信任度, 并依赖信任度预测任务标签。随后, 从理论上证明了所提方法具有低反悔界, 表明该方法收敛于最优决策。最后, 通过人工合成众包数据以及真实众包数据上的数值实验验证了所提方法的有效性。

关键词 众包回归; 在线学习; 质量控制; 聚合

Online Aggregation for Crowdsourcing Regression

JIAN Ling¹, CHEN Xingke², ZHOU Peng¹

(1. School of Economics and Management, China University of Petroleum, Qingdao 266580, China;
2. College of Science, China University of Petroleum, Qingdao 266580, China)

Abstract As an effective and low-cost way to fetch training data from workers, crowdsourcing services have become a popular choice for Internet giants. However, the obtained labels may be flawed due to the errors and noise from annotation processes, which limits the performance of downstream data mining tasks seriously. To address the issue, we propose Crowdsourcing Regression Online Aggregation Method, a semi-supervised crowdsourcing regression algorithm based on normalized exponential gradient strategy. This algorithm is capable of adjusting the degree of trust according to the performances of varied workers dynamically and predicts new instances in an online way. In addition, we prove that our method has a low regret bound and show its effectiveness via multiple numerical experiments on synthetic and real-world crowdsourcing datasets.

Keywords crowdsourcing regression; online learning; quality control; aggregation

1 引言

众包指企业或者机构将自身无法独立完成的大量甚至海量任务通过互联网发布、分配给为数众多的普通网民, 并由网民完成的做法^[1]。一些影响深远的工程, 例如维基百科、百度知道、ImageNet 视觉资料库等都是通过众包模式进行实施的。在过去的十年中, 众包模式已经惠及全球, 并成为数据挖掘和数据管理领域的研究热点^[2]。伴随互联网技术、移动互联网技术的不断发展, 众包应用已逐步渗透到各行各业, 导致众包服务的需求量不断增大、任务的形式日趋增多。特别地, 在当前的大数据时代, 深度学习已成为处理语音识别、计算机视觉、自然语言处理、股票市场预测等复杂学习任务的首选工具^[3]。然而, 大规模带标签学习样本是深度学习实现知识发现、规律获取的基础, 众包模式则是当前获取大规模训练数据(如ImageNet)的主流方法^[4]。在此背景下, 在线众包服务平台应运而生。近年来, 国内外信息科技公司先后搭建了众包平台提供相关服务, 主要包括亚马逊的Mechanical Turk和CrowdFlower、百度的数据众包平台和阿里巴巴的阿里众包等, 大量众包服务工作者通过互联网或移动互联网参与完

成众包任务^[5], 这些任务涉及出行、餐饮、推荐、图片标定、交通信息采集等诸多应用领域^[6]。众包服务平台通过搭建廉价劳动力市场, 将大量分类、回归等任务以外包方式分发给愿意以低薪酬解决此类任务的大量众包工作者。但是, 由于薪酬低且任务繁琐, 即使有责任心工作者也容易出错。况且众包工作者中不乏恶意骗取酬金者, 其提供的多是垃圾标签参考价值有限。以上原因导致众包平台收集到的样本标签中富含噪音^[7-9]。为此, 增加参与任务的工作者数量成为领域内广泛使用的策略。该策略将众包任务分配给多个工作者, 并将收集到的众包标签通过聚合方法(如简单平均)进行汇总^[8]。由于工作者的素质参差不齐, 且各工作者的性能表现具有动态时变的特征。如何从大量富含噪音的标签数据中获取可信标签, 对数据进行高精度标注是当前众包服务面临的重要挑战^[8,9]。

国内外学者针对众包标签质量控制问题开展了大量研究, 提出了一系列处理方法。Tong等人^[10]提出了一种面向众包标签的数据清洗框架。Wang等人^[11]提出通过对众包工作者以往工作质量进行学习并据此判断其提供标签的准确性, 基于此提出了识别算法以筛选众包工作者中的恶意工作者。Dawid等人提出了一种基于极大似然估计的EM算法^[12], 试图从高质量工作者中识别部分带有偏见的工作者。针对众包分类问题, Hu等人研究了多工作者完成众包任务的问题, 发现当每个项目由不同工作人员进行标记时, 投票策略是简单而直接的聚合策略, 采用出现次数最多标签作为预测标签的平均效果优于单个工作者^[13]。然而, 投票策略独立处理每个任务, 在处理系列任务时并未考虑工作者的绩效。为此, Platt等人假设工作者在不同任务上的绩效具有一致性, 并基于该假设提出了标签质量改进方法^[14]。针对众包回归问题, 最近学者们提出了几种新颖的算法: Raykar等人^[15]基于最大似然估计提出了一种概率模型, 但没有分析模型的理论性质。Parde等人^[16]提出了随机子空间回归算法, 用来处理无监督众包回归问题。Jungseul等人^[17]提出了一种迭代Bayesian学习算法, 学习工作者的异质性特征。

然而, 众包任务中存在大量带有时间属性的任务如时空众包任务等^[18]。随着时间的推移, 众包平台不断发布任务并由不同的工作者共同参与标记。而众包工作者的完成质量并非保持不变, 精准追踪工作者完成质量并依赖该指标动态调整对其的信任度, 根据不同工作者的信任度和标签预测该任务标签, 是进一步提升标签质量的可靠保障。鉴于此, 本文在线凸优化理论框架下^[19], 提出了一种基于标准指数梯度算法框架(NEG)的众包回归在线聚合方法, 主要贡献包括:

1. 采用NEG算法框架, 实现工作者信任度的动态调整;
2. 采用在线凸优化理论分析所提在线聚合方法的反悔界为 $L\sqrt{2(\log d)n}$;
3. 通过人工合成数据和真实众包回归数据上的数值实验, 说明所提方法的有效性。

2 问题描述

2.1 半监督众包回归问题

本文在半监督众包回归分析的场景下开展研究, 将已知答案任务和实际任务混合后分配给众包工作者进行标注, 根据工作者在已知答案任务上的标注动态调整对其信任度 w , 并依赖信任度预测实际任务标签 \hat{y} 。

众包工作者在完成一系列平台发布的任务时, 其工作表现并非一成不变, 及时追踪工作者的工作完成质量并依赖该指标动态调整对其信任度, 并根据信任度和标签信息确定该任务标签, 是实现众包任务质量控制的有效手段。为此, 我们将已知答案任务随机均匀分布于实际任务之中。假设众包发布者共发布了 n 个带答案回归任务, 用 $\mathbf{T} = \{t_{a_1}, t_{a_2}, \dots, t_{a_n}\}$ 表示, 其中第 a_i 项任务的真实标签用 $y_{a_i} \in \mathbb{R}$ 表示。根据已知答案任务的完成情况动态调整对众包工作者的信任度, 并依赖信任度估计实际众包任务的真实标签。众包服务平台将全部众包任务分配给 d 个众包工作者进行人工标注, 假设这 d 个众包工作者在第 i 项任务上的标注为 $\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{id}]^T \in \mathbb{R}^d$, 聚合方法在第 i 项任务上对工作者的信任度为 $\mathbf{w}_i = [w_{i1}, w_{i2}, \dots, w_{id}]^T \in \mathbb{R}^d$, 则聚合方法对第 i 项任务的预测标签为 $\hat{y}_i = \langle \mathbf{w}_i, \mathbf{x}_i \rangle$ 。信任度 w 的动

态调整是提升众包任务完成质量的关键, 为此本文基于在线学习理论, 开展半监督众包回归在线聚合方法研究(如图1所示), 以为众包回归问题提供可靠解决方案。

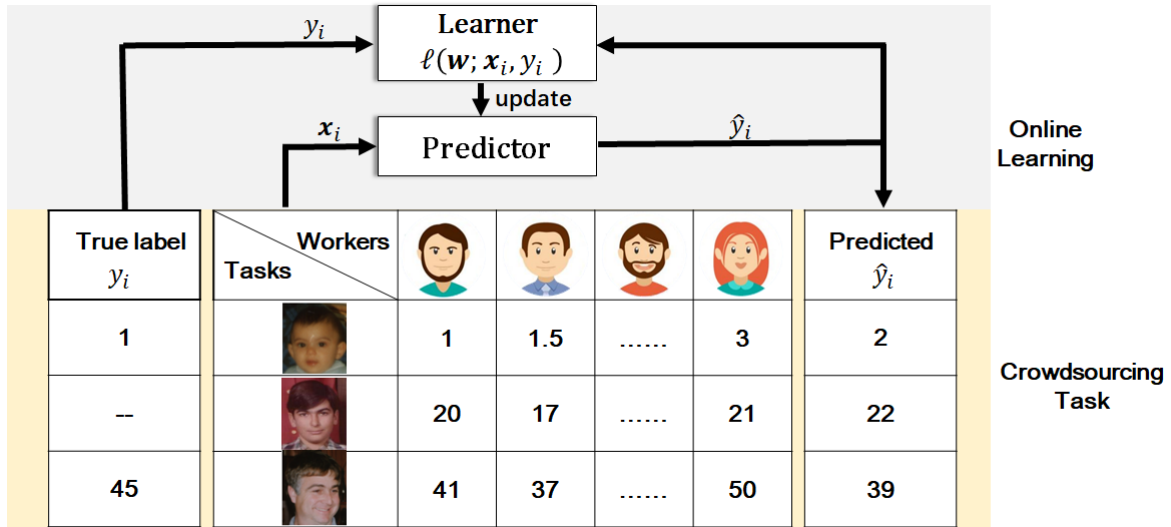


图1 半监督众包回归的在线聚合方法示意图

2.2 在线学习

深度学习、支持向量机等基于批处理方式的传统机器学习算法在处理在线广告、量化投资、众包数据分析等数据流挖掘问题存在计算复杂度高、模型更新效率低、实时性差等诸多不足。基于在线凸优化理论, 2003年Zinkevich建立了在线学习基本框架^[19]。在线学习基于逐点学习策略(如图2所示), 通过动态更新模型逐点学习样本数据,




图2 在线学习示意图

模型更新一次的计算量仅为 $O(1)$, 具有计算复杂度低、模型更新效率高、实时性强等优势, 是处理数据流分析问题的天然工具。近年来, 逐渐成为数据挖掘新范式, 是数据流挖掘的主流方法^[20]。国内外学者们围绕在线学习算法与理论开展了大量研究工作, 提出了一系列算法包括: Online Gradient Descent (OGD)算法、Online Mirror Descent (OMD)算法等^[21], 这些在线学习算法被广泛应用于在线广告、量化投资、推荐系统、在线调度等领域^[22,23]。本文将基于在线学习的基本范式, 开展面向众包回归问题的在线聚合方法研究。

3 基于NEG的众包回归在线聚合方法

3.1 算法实现

根据2.1节半监督众包回归问题的描述可知,众包工作者的信任度 \mathbf{w} 是决策变量,亦是在线聚合方法需要优化的关键变量。假设众包工作者的信任度 \mathbf{w} 满足:1)各分量具有非负性;2)各分量加和为1,即 $\mathbf{w} \in \mathcal{P} = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{w} \geq 0 \wedge \|\mathbf{w}\|_1 = 1\}$ 。在线聚合方法在处理第 i 个任务时,依据当前信任度 \mathbf{w}_i 对众包工作者提供的标签 \mathbf{x}_i 作加权平均处理,所得预测标签为 $\hat{y}_i = \langle \mathbf{w}_i, \mathbf{x}_i \rangle$ ($\langle \cdot, \cdot \rangle$ 表示向量内积运算)。本文选择具有良好光滑化性质的平方损失作为损失函数,则在线聚合方法在第 i 个任务上的损失为:

$$\ell_i(\mathbf{w}) = \frac{1}{2} (\hat{y}_i - y_i)^2 = \frac{1}{2} (\langle \mathbf{w}, \mathbf{x}_i \rangle - y_i)^2, \quad (1)$$

由于集合 \mathcal{P} 是概率单纯形,显然是凸集,且损失函数 $\ell_i(\mathbf{w})$ 为凸函数(见定理1),故优化 $\ell_i(\mathbf{w})$ 的问题是一个凸优化问题。为了保证在优化累积损失 $\sum_i \ell_i(\mathbf{w})$ 的过程中信任度 \mathbf{w} 保持稳定,本文在Follow-The-Regularized-Leader的算法框架下对 \mathbf{w} 迭代优化^[21]。NEG算法是处理该类型问题的有效算法,具有坚实的理论基础。近年来,NEG算法已被广泛应用于基于专家意见的预测等诸多实际问题,并取得了较好的应用效果。基于NEG算法框架,我们提出了半监督众包回归在线聚合方法如下:

算法 1 基于NEG框架的半监督众包回归在线聚合方法

```

1: 初始化: 学习率参数 $\eta$ ,  $\mathbf{w}_1 = [\frac{1}{d}, \dots, \frac{1}{d}]^T$ 
2: for  $i = 1, 2 \dots$  do
3:   获得第 $i$ 个任务的众包工作者标注 $\mathbf{x}_i \in \mathbb{R}^d$ ;
4:   根据信任度 $\mathbf{w}_i$ 产生预测标签 $\hat{y}_i = \langle \mathbf{w}_i, \mathbf{x}_i \rangle$ ;
5:   if 获得真实标签为 $y_i \in \mathbb{R}$  then
6:     计算损失函数的梯度 $\mathbf{z}_i = \nabla \ell_i(\mathbf{w})|_{\mathbf{w}=\mathbf{w}_i} = (\langle \mathbf{w}, \mathbf{x}_i \rangle - y_i) \mathbf{x}_i$ ;
7:     更新信任度参数 $\mathbf{w}_{i+1}[j] = \frac{\mathbf{w}_i[j] e^{-\eta \mathbf{z}_i[j]}}{\sum_j \mathbf{w}_i[j] e^{-\eta \mathbf{z}_i[j]}}$ ,  $j = 1, \dots, d$ ;
8:   else
9:     保持信任度参数 $\mathbf{w}_{i+1} = \mathbf{w}_i$ ;
10:  end if
11: end for

```

3.2 在线聚合方法的反悔界分析

本节对所提在线聚合方法的理论性质进行分析,为其实际应用提供理论保障。

定理1. 假设样本点 (\mathbf{x}_i, y_i) 处的损失函数 $\ell_i(\mathbf{w}) = \frac{1}{2} (\langle \mathbf{w}, \mathbf{x}_i \rangle - y_i)^2$ 梯度有界,即 $\forall \mathbf{z}_i = \nabla \ell_i(\mathbf{w}_i)$ 均有 $\|\mathbf{z}_i\|_\infty \leq L$,即 $|\mathbf{z}_i[j]| \leq L, j = 1, \dots, d$,则众包回归在线聚合方法 \mathcal{A} 的反悔界为

$$\text{Regret}_T(\mathcal{A}) = \max_{\mathbf{u} \in \mathcal{P}} \sum_{i=1}^n (\ell_i(\mathbf{w}_i) - \ell_i(\mathbf{u})) \leq \frac{\log d}{\eta} + \frac{\eta}{2} n L^2.$$

特别地,令 $\eta = \frac{1}{L} \sqrt{2(\log d)/n}$ 可得所提算法 \mathcal{A} 的反悔界(关于最优决策)为 $L \sqrt{2(\log d)n}$ 。

证明. 令 $\ell(\mathbf{w}) = \frac{1}{2} (\langle \mathbf{w}, \mathbf{x} \rangle - y)^2$,由 $\nabla^2 \ell(\mathbf{w}) = \mathbf{x}^T \mathbf{x} \succcurlyeq \mathbf{0}$,可知 $\ell(\mathbf{w})$ 为凸函数即 $\ell_i(\mathbf{w}), (i = 1, \dots, n)$ 为凸函数。根据引理2,

$$\ell_i(\mathbf{w}_i) - \ell_i(\mathbf{u}) \leq \langle \mathbf{w}_i, \mathbf{z}_i \rangle - \langle \mathbf{u}, \mathbf{z}_i \rangle,$$

其中 $\mathbf{z}_i = \nabla \ell_i(\mathbf{w}_i)$ 。众包回归在线聚合方法 \mathcal{A} 等价于指定损失函数为线性损失 $\langle \mathbf{w}, \mathbf{z} \rangle$ 情况下运行NEG算法,故引理5成立,则

$$\sum_{i=1}^n \langle \mathbf{w}_i, \mathbf{z}_i \rangle - \sum_{i=1}^n \langle \mathbf{u}, \mathbf{z}_i \rangle \leq \frac{\log d}{\eta} + \frac{\eta}{2} \sum_{i=1}^n \|\mathbf{z}_i\|_\infty^2,$$

由此可得

$$\text{Regret}_T(\mathcal{A}) = \max_{\mathbf{u} \in \mathcal{P}} \sum_{i=1}^n (\ell_i(\mathbf{w}_i) - \ell_i(\mathbf{u})) \leq \max_{\mathbf{u} \in \mathcal{P}} \sum_{i=1}^n (\langle \mathbf{w}_i, \mathbf{z}_i \rangle - \langle \mathbf{u}, \mathbf{z}_i \rangle) \leq \frac{\log d}{\eta} + \frac{\eta}{2} \sum_{i=1}^n \|\mathbf{z}_i\|_\infty^2.$$

由定理假设条件 $\|\mathbf{z}_i\|_\infty \leq L$ 可证结论。

在设置学习率参数 $\eta = \frac{1}{L} \sqrt{2(\log d)/n}$ 的条件下,可收紧所提方法 \mathcal{A} 的反悔界为 $L \sqrt{2(\log d)n}$ 。 □

当前流行的随机选择方法的反悔界为 $2L\sqrt{(\log d)n}$, 与之相比本文所提在线聚合方法在收敛速度方面有了 $\sqrt{2}$ 倍的提升, 即在线聚合方法仅需一半的迭代轮次便可达到与随机选择方法相同的精度要求。因此, 从理论上讲本文所提在线聚合方法在处理众包回归问题时应该具有更好的性能表现。下面我们将通过数值实验对理论结果进行验证。

4 数值实验

本节通过人工合成众包数据和真实众包数据上的数值实验, 验证所提方法的有效性。实验所使用的软硬件环境具体配置为处理器Intel (R) Core (TM) i5-7200 CPU@2.70GHz内存为8GB, 操作系统为Windows 10, 编程语言为Python 2.7。本节主要对比如下两种常用众包数据聚合方法:

1. 简单平均方法-直接使用工作者标签的平均值作为预测输出, 并未考虑工作者的性能表现;
2. 随机选择方法-基于工作者的性能表现, 构造概率分布并依赖该分布随机选取一个工作者的标签作为方法预测输出。

4.1 人工合成数据实验

在像素值为 100×100 的图像中随机均匀选择像素点, 并以该点灰度值作为本轮任务的真实标签。我们设定有10个工作者参与标注, 他们被分为优、良、中、差4个等级, 其中每个等级的人数分别设置为2, 3, 3, 2。通过方差来刻画工作者的性能表现: $S_1 = 0.2, 0.5, 0.8, S_2 = 2, 5, 8, S_3 = 20, 50, 80, S_4 = 100, 110, 120$ 。在每一个任务上随机从相应等级的方差集合中选择每个等级工作者的方差, 学习率设为 $\eta = 0.01$ 。实验选取平均绝对误差(MAE)作为性能评价指标, 在该数据上进行10次随机实验, 得到了众包回归在线聚合方法、简单平均方法和随机采样方法的表现(考虑到各方法的MAE指标在第1000个样本点以后均达到稳定状态, 为了提高清晰性, 图3仅展示各方法在前1500个样本上的表现)。




图3 三种算法在人工合成数据上的表现

由图3中可见, 简单平均方法的平均绝对值误差未能收敛到0, 这是由于该方法未对工作者的信任度进行调整, 方法预测结果受到低质量工作者的标签(高噪音)影响造成的。随机采样方法采用了信任度调整策略, 使得性能有较大提升, 但仍有方差较大、稳定性不足的缺陷。众包回归在线聚合方法克服了简单平均方法不进行信任度调整和随机采样方法方差偏大的缺点, 在MAE指标和收敛速度方面较两种对比方法均有更大改进。




图4 众包回归在线聚合算法信任度变化曲线, 其中工作者1和2为优级工作者

图4给出了固定学习率参数 $\eta = 0.01$ 情况下, 信任度 w_t 的变化曲线, 由图可见两个优等级的工作者工作者1和工作者2的信任度在0.5附近, 而其余工作者的信任度均收敛到0, 这意味着众包回归在线聚合方法可筛选出全部优等级工作者, 同时消除了质量较差的标注数据对模型的负面影响(如图4所示), 该性质表明所提众包回归在线聚合方法的有效性, 对众包数据挖掘具有重要意义。

4.2 真实众包数据实验

本节选择亚马逊Mechanical Turk(MTurk)平台上收集到的隐喻新颖性打分数据集^[16]以及面部图像数据集FG-NET^[25]两个真实众包数据验证我们所提基于NEG的众包回归在线聚合方法的有效性。

学习率参数 η , 是所提方法的关键参数, 根据定理1为保障最优学习效果, 理论上的最优学习率参数 η 应设为 $\eta = \frac{1}{L} \sqrt{2(\log d)/n}$ 。但在处理实际问题时, 由于众包任务是动态发布的, 任务总量 n 事先无法精确预知。本文采用Doubling trick的方式^[21]分区间确定步长。为说明该参数设置的有效性, 我们通过实验对比了如下三种步长设置方式:

1. 固定学习率参数, 设置 $\eta = 0.01$;
2. 通过Oracle方式获取任务总量 n , 进而估计最优学习率参数 $\eta = \frac{1}{L} \sqrt{2(\log d)/n}$;
3. 通过Doubling trick方式分区间动态确定学习率参数 η : 在样本索引区间 $[2^m, 2^{m+1} - 1]$ 上设置 η 为 $\frac{1}{L} \sqrt{2(\log d)/2^m}$, 非负整数。

下面, 我们将本文所提出的众包回归在线聚合方法分别与三种步长策略结合, 并通过隐喻新颖性打分数据集和面部图像FG-NET数据集上的数值实验对三种步长策略进行对比分析。

隐喻评分数据^[16] 来源于自然语言处理问题的数据, 要求众包工作者通过离散等级(从非隐喻到高度新颖的隐喻)对给定实例的隐喻新颖性进行评分。本数据集通过众包平台共获取了3112个实例的隐喻新颖性标注(如表1所示)。全部实例由VU Amsterdam 隐喻语料库的单词生成, 这些单词均带有隐喻新颖性标注且隐喻新颖性变化很大(由普通到极其新颖)。语言学专家对全部3112组数据进行人工标注, 以此作为实例的真实标签。

表1 隐喻新颖性打分示例

Sample	Score
Alice looked up, and there stood the Queen in front of them, with her arms folded, <i>frowning</i> like thunderstorm .	Novel Metaphor(3)
‘Once,’ said the Mock Turtle at last, with a deep sign , ‘I was a real Turtle.’	Conventional Metaphor(1)
A large rose-tree stood near the <i>entrance</i> of the garden: the roses growing on it were white, but there were three gardeners at it, busily painting them red.	Non-Metaphor(0)

该数据集共有5名工作者($d = 5$), 3112个实例($n = 3112$), 打分区间为 $[0, 3]$, 故可以估计出 $L = 9$, 由此可得Oracle策略下的步长。三种步长策略在隐喻新颖性打分数据集上的表现如图5所示, 由于采用Oracle步长策略的步长较小且在算法执行过程中始终保持不变, 在开始阶段收敛最慢。Doubling trick策略在开始阶段步长最大, 相比其他两种方法具有更快的收敛速率。




图5 不同步长策略在隐喻新颖性打分数据集上表现

信任度方面, 常数步长策略由于在算法迭代过程中步长保持不变, 在算法迭代的后期步长相对偏大, 导致该策略得到的信任度不稳定而Oracle策略和Doubling trick策略能够收敛到稳定权重, 并且Doubling trick策略能够最快达到稳定状态, 说明Doubling trick策略具有较好的稳定性。




图6 不同步长策略在隐喻新颖性打分数据集上信任度变化情况, 由左到右依次为常数步长、Oracle和Doubling trick策略

面部图像年龄数据 FG-NET数据集共1002张图像,每张图像均包含了10个工作者对图像人物年龄的标注信息^[25],图7给出了FG-NET数据集的样本示例。



图7 面部图像数据库FG-NET样本示例

10名工作者在1002张图像数据的标注任务中的性能表现如表2所示。根据表格2的统计数据,工作者的最大绝对误差为88, MAE指标显示第6个工作者的表现最优,而RMSE指标则表明第7个工作者的表现最优, MAE和RMSE两个性能指标显示10个众包工作者的性能表现并没有明显差异。

表2 众包工作者的标签统计特征

Worker	1	2	3	4	5	6	7	8	9	10
MAE	5.48	5.53	5.77	5.73	5.46	5.42	5.55	5.70	5.55	5.61
RMSE	8.23	8.25	8.39	8.46	8.14	8.21	8.10	8.70	8.35	8.23
Max	49	49	45	42	45	52	55	88	47	40
Min	0	0	0	0	0	0	0	0	0	0

该数据集共有10名工作者($d = 10$), 1002个实例($n = 1002$), 打分区间为 $[0, 100]$, 由此预估 $L = 8624$, 进而可得Oracle策略下的步长。结合三种步长策略的众包回归在线聚合方法在面部图像数据集上的表现如图8所示。由图可得如下观察: 三种策略中, Oracle步长策略具有最优的MAE表现和相对较小的方差, 因此较好地支持了理论分析结果; 固定步长策略($\eta = 0.01$)的表现较差, 随着样本数量增加, 难以达到和Oracle步长策略相近的表现; 而本文所采用的Doubling trick策略尽管在前期与Oracle策略有一定差距, 但随着训练样本的增加和步长的逐步缩减, 最终能得到近似Oracle策略的表现。表明Doubling trick是实际可行的步长策略。

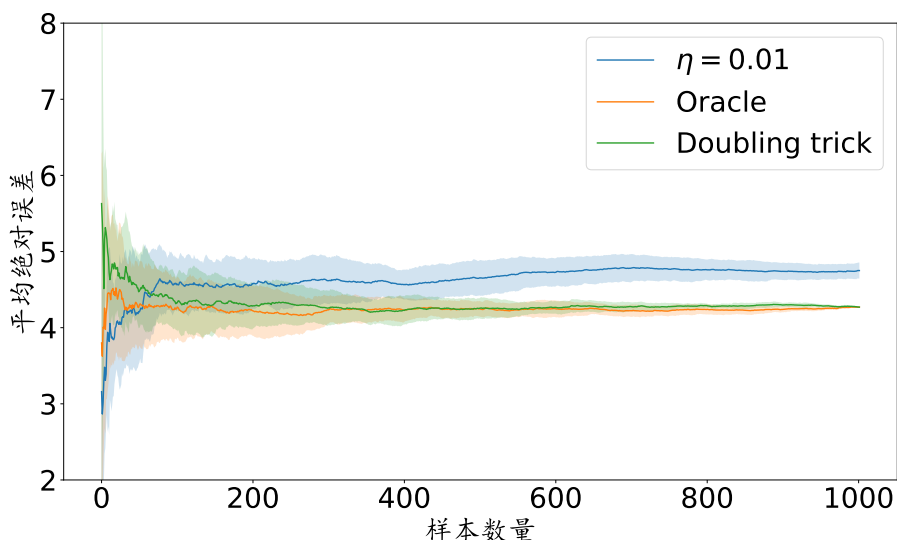


图8 不同步长策略在面部图像数据集上表现

5 结论

众包服务作为基于网络的在线分布式问题解决和知识生产模式,以互联网平台为渠道,通过公开自愿的形式号召大众将自己的知识技能向企业/组织分享,为既有知识技能又有空闲时间的大众提供

了创造共享价值的平台。众包数据的质量控制是众包服务平台关注的核心问题。面向半监督众包回归问题, 本文基于NEG算法框架提出了一种新型众包回归在线聚合方法, 根据不同工作者完成一系列众包任务时的动态表现不断调整对其信任度, 并利用信任度对工作者的标签进行加权聚合, 进而预测任务标签, 以提升众包回归数据的数据质量。基于在线凸优化理论证明所提方法的反悔界为 $L\sqrt{2(\log d)n}$, 从理论上保证了所提方法可收敛到最优决策。最后, 在人工合成数据和真实众包数据上的实验表明了所提方法的有效性。

有待进一步深入研究方向主要包括: 1) 结合有序回归问题的典型算法, 围绕推荐打分等具有有序回归特征的众包回归问题开展针对性建模研究; 2) 结合众包任务的异质性特征, 综合考虑任务难度和工作者绩效两方面信息开展协同建模研究, 进一步提升众包数据分析质量。

5 附录

引理1. 函数 $f(\mathbf{w})$ 二阶连续可微, 若对任意 \mathbf{w} 和 \mathbf{x} 均有 $\langle \nabla^2 f(\mathbf{w}) \mathbf{x}, \mathbf{x} \rangle \geq \sigma \|\mathbf{x}\|_*^2$, 则 $f(\mathbf{w})$ 为关于 $\|\cdot\|_*$ 的 σ -强凸函数。

证明. 见文献[19]引理14. □

引理2. 若凸函数 $f(\mathbf{w})$ 连续可微, 则对于任意 \mathbf{w} 和 \mathbf{u} , 均有 $f(\mathbf{w}) - f(\mathbf{u}) \leq \langle \mathbf{w}, \mathbf{z} \rangle - \langle \mathbf{u}, \mathbf{z} \rangle$, 其中 $\mathbf{z} = \nabla f(\mathbf{w})$ 。

证明. 凸函数 $f(\mathbf{w})$ 连续可微, 故由凸函数的等价定义可知对于任意 \mathbf{w} 和 \mathbf{u} , $f(\mathbf{u}) \geq f(\mathbf{w}) + \langle \mathbf{u} - \mathbf{w}, \mathbf{z} \rangle$ 。整理可得 $f(\mathbf{w}) - f(\mathbf{u}) \leq \langle \mathbf{w}, \mathbf{z} \rangle - \langle \mathbf{u}, \mathbf{z} \rangle$ 。 □

引理3. 假设 $R(\cdot) : \mathcal{P} \rightarrow \mathbb{R}$ 关于范数 $\|\cdot\|_p$ 为 $\frac{1}{\eta}$ -强凸函数, 运行 OMD 算法所得序列为 $\mathbf{w}_1, \dots, \mathbf{w}_n \in \mathcal{P}$, 则有 $\sum_{i=1}^n \langle \mathbf{w}_i, \mathbf{z}_i \rangle - \sum_{i=1}^n \langle \mathbf{u}, \mathbf{z}_i \rangle \leq R(\mathbf{u}) - R(\mathbf{w}_1) + \frac{\eta}{2} \sum_{i=1}^n \|\mathbf{z}_i\|_q^2$, 其中 $\|\cdot\|_q$ 与 $\|\cdot\|_p$ 互为对偶范数。

证明. 见文献[17]定理2.21. □

引理4. 负熵正则化函数 $R(\mathbf{w}) = \sum_{i=1}^d w[i] \log(w[i])$ 关于 $\|\cdot\|_1$ 为 1-强凸函数, 其中

$$\mathbf{w} \in \mathcal{P} = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{w} \geq 0 \wedge \|\mathbf{w}\|_1 = 1\}$$

。

证明. 对任意的 $\mathbf{w} \in \mathcal{P}$ 和 $\mathbf{x} \in \mathbb{R}^d$, 由

$$\langle \nabla^2 R(\mathbf{w}) \mathbf{x}, \mathbf{x} \rangle = \sum_{i=1}^d \frac{x[i]^2}{w[i]} = \frac{1}{\|\mathbf{w}\|_1} \left(\sum_{i=1}^d w[i] \right) \left(\sum_{i=1}^d \frac{x[i]^2}{w[i]} \right) \geq \frac{1}{\|\mathbf{w}\|_1} \left(\sum_{i=1}^d \sqrt{w[i]} \frac{|x[i]|}{\sqrt{w[i]}} \right)^2 = \frac{\|\mathbf{x}\|_1^2}{\|\mathbf{w}\|_1} = \|\mathbf{x}\|_1^2,$$

故 $R(\mathbf{w}) = \sum_{i=1}^d w[i] \log(w[i])$ 关于 $\|\cdot\|_1$ 为 1-强凸函数。易证 $\frac{1}{\eta} \sum_{i=1}^d w[i] \log(w[i]) \geq \frac{1}{\eta} \|\mathbf{x}\|_1^2$, 故 $\frac{1}{\eta} \sum_{i=1}^d w[i] \log(w[i])$ 关于 $\|\cdot\|_1$ 为 $\frac{1}{\eta}$ -强凸函数。 □

引理5. 假设损失函数为 $\ell(\mathbf{w}) = \langle \mathbf{w}, \mathbf{z} \rangle$, 由 NEG 算法得到一系列预测

$$\mathbf{w}_1, \dots, \mathbf{w}_n \in \mathcal{P} = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{w} \geq 0 \wedge \|\mathbf{w}\|_1 = 1\},$$

则有

$$\sum_{i=1}^n \langle \mathbf{w}_i, \mathbf{z}_i \rangle - \sum_{i=1}^n \langle \mathbf{u}, \mathbf{z}_i \rangle \leq \frac{\log d}{\eta} + \frac{\eta}{2} \sum_{i=1}^n \|\mathbf{z}_i\|_\infty^2$$

其中, \mathbf{u} 为可行集 \mathcal{P} 的任意变量。

证明. 在 OMD 算法框架下, 令正则化函数 $R(\mathbf{w}) = \frac{1}{\eta} \sum_{i=1}^d w[i] \log(w[i])$, $\mathcal{P} = \{\mathbf{w} \in \mathbb{R}^d : \mathbf{w} \geq 0 \wedge \|\mathbf{w}\|_1 = 1\}$, 所得算法即为 NEG 算法。由引理3 及引理4 可知

$$\sum_{i=1}^n \langle \mathbf{w}_i, \mathbf{z}_i \rangle - \sum_{i=1}^n \langle \mathbf{u}, \mathbf{z}_i \rangle \leq R(\mathbf{u}) - R(\mathbf{w}_1) + \frac{\eta}{2} \sum_{i=1}^n \|\mathbf{z}_i\|_\infty^2,$$

而 $\min_{\mathbf{w}_1 \in \mathcal{P}} R(\mathbf{w}_1) = -\frac{\log d}{\eta}$, $\max_{\mathbf{u} \in \mathcal{P}} R(\mathbf{u}) = 0$, 可得引理5 结论。 □

参考文献

- [1] 陆赞. 众包活动中接包方参与意愿影响因素研究[D]. 南京大学, 2018.
- [2] 仲秋雁, 张媛, 李晨, 等. 考虑用户兴趣和能力的众包任务推荐方法[J]. 系统工程理论与实践, 2017, 37(12):3270-3280.
- [3] 陈卫华, 徐国祥. 基于深度学习和股票论坛数据的股市波动率预测精度研究. 管理世界, 2018, 34(1):180-181.
- [4] 林素芬, 林峰. 众包定义、模式研究发展及展望. 科技管理研究, 2015, 35(4):212-217.
- [5] Howe J. Crowdsourcing: Why the Power of the Crowd Is Driving the Future of Business. Crown Publishing Group, 2010.
- [6] 郭崇慧, 许蒙. 一种基于众包模式的试题知识点标注方法. 信息与管理研究, 2019, 4(6):64-72.
- [7] 郭文波, 张朋柱, 葛如一. 基于过程模型的众包市场信任增进机制[J]. 系统管理学报, 2016, 25(1):115-120.
- [8] 张志强, 逢居升, 谢晓芹. 众包质量控制策略及评估算法研究. 计算机学报, 2013, 36(8):1636-1649.
- [9] 初翔, 仲秋雁. 支持工作者位置隐私保护的众包质量控制模型[J]. 系统工程理论与实践, 2016, 36(8):2047-2055.
- [10] Tong Y, Cao C C, Zhang C J, et al. Crowdcleaner: Data cleaning for multi-version data on the web via crowdsourcing. IEEE 30th International Conference on Data Engineering, 2014, 1182-1185.
- [11] Ipeirotis P G, Provost F, Wang J. Quality management on Amazon Mechanical Turk. Proceedings of the ACM SIGKDD workshop on human computation, 2010, 64-67.
- [12] Dawid A P, Skene A M. Maximum likelihood estimation of observer error-rates using the EM algorithm. Journal of the Royal Statistical Society, 1979, 28(1):20-28.
- [13] Hu H, Zheng Y, Bao Z, et al. Crowdsourced poi labelling: Location-aware result inference and task assignment. 32nd IEEE International Conference on Data Engineering, 2016, 61-72.
- [14] Zhou D, Platt J C, Basu S, et al. Learning from the wisdom of crowds by minimax entropy. Advances in Neural Information Processing Systems, 2012, 2204-2212.
- [15] Raykar V C, Yu S, Zhao L H, et al. Learning from crowds. Journal of Machine Learning Research, 2010, 11:1297-1322.
- [16] Parde N, Nielsen R. Finding patterns in noisy crowds: Regression-based annotation aggregation for crowdsourced data. In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, 2017, 1907-1912.
- [17] Ok J, Oh S, Jang Y, et al. Iterative Bayesian learning for crowdsourced regression. In The 22nd International Conference on Artificial Intelligence and Statistics, 2019, 1486-1495.
- [18] 宋天舒, 童咏昕, 王立斌. 许可空间众包环境下的3类对象在线任务分配. 软件学报, 2017, 3:611-630.
- [19] Zinkevich M. Online convex programming and generalized infinitesimal gradient ascent. In Proceedings of the Twentieth International Conference on Machine Learning, 2003, 928 - 936.
- [20] Hoi S C H, Wang J, Zhao P. Libol: A library for online learning algorithms. Journal of Machine Learning Research, 2014, 15:495 - 499.
- [21] Shalev-Shwartz S. Online learning and online convex optimization. Foundations and Trends in Machine Learning, 2011, 4(2):107 - 194.
- [22] 黄嵩, 倪宣明, 钱龙, 等. 基于集成学习的在线高维投资组合策略. 系统科学与数学, 2020, 40(1):29-40.
- [23] 王征, 李婷玉, 岳彩凡. 同城即时配送问题基于多预测场景的在线调度[J]. 系统工程理论与实践, 2018, 38(12):207-221.
- [24] Boyd S, Vandenberghe L, Convex Optimization[M]. Cambridge University Press, 2004.
- [25] Han H, Otto C, Liu X, et al. Demographic estimation from face images: human vs. machine performance. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(6):1148-1161.
- [26] Shalev-Shwartz S and Singer Y. Online Learning: Theory, algorithms, and applications. 2007.